



| Feature A | Feature B | Feature C | Target |
|-----------|-----------|-----------|--------|
| Yes | Yes | 205 | Yes |
| No | Yes | 180 | Yes |
| Yes | No | 210 | Yes |
| Yes | Yes | 167 | Yes |
| No | Yes | 156 | No |
| No | No | 125 | No |

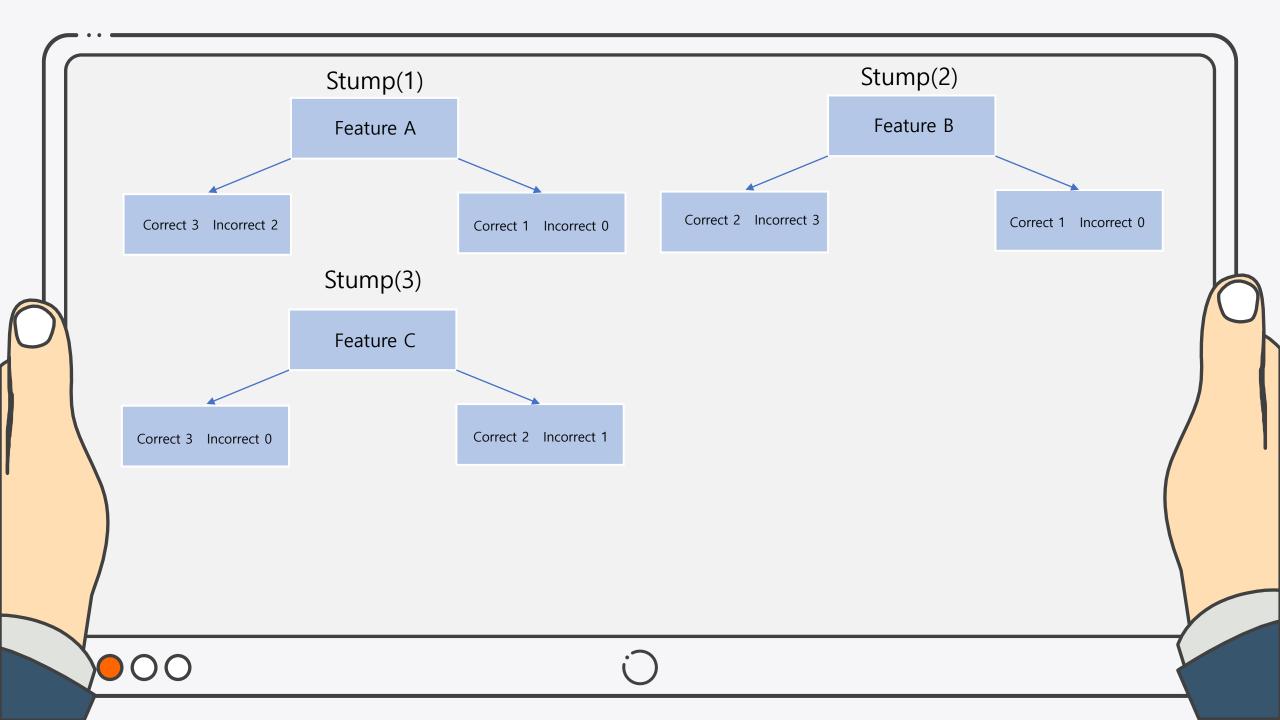


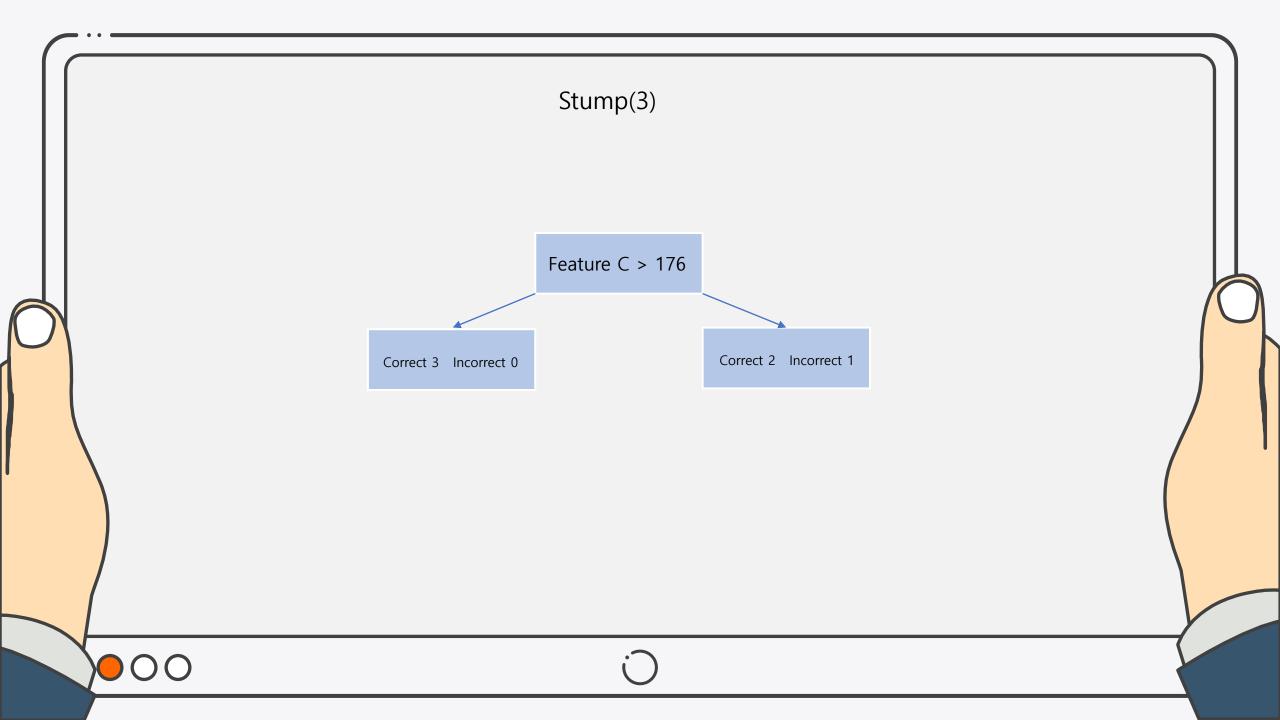


| Feature A | Feature B | Feature C | Target | 가증치 |
|-----------|-----------|-----------|--------|---------------|
| Yes | Yes | 205 | Yes | |
| No | Yes | 180 | Yes | 1 |
| Yes | No | 210 | Yes | $\frac{1}{6}$ |
| Yes | Yes | 167 | Yes | |
| No | Yes | 156 | No | |
| No | No | 125 | No | |





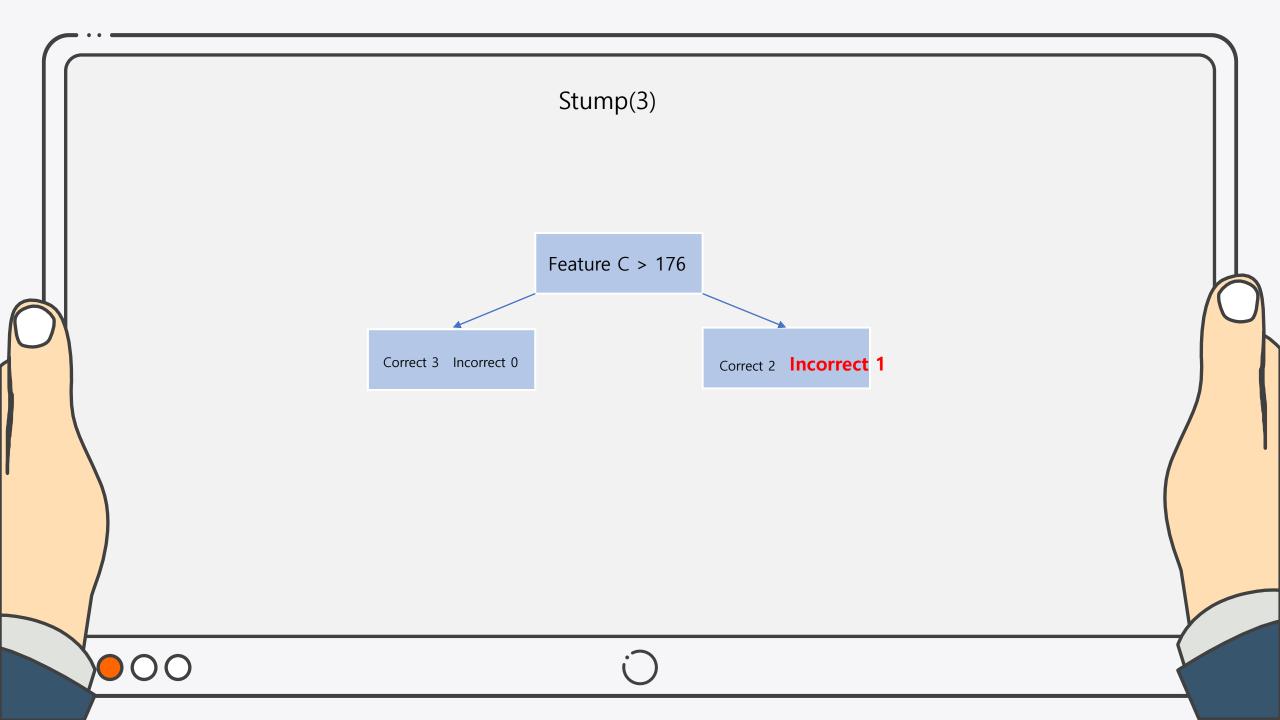




| Feature A | Feature B | Feature C | Target | 가증치 |
|-----------|-----------|-----------|--------|---------------|
| Yes | Yes | 205 | Yes | |
| No | Yes | 180 | Yes | 1 |
| Yes | No | 210 | Yes | $\frac{1}{6}$ |
| Yes | Yes | 167 | Yes | |
| No | Yes | 156 | No | |
| No | No | 125 | No | |







Total Error = 오류가 난 데이터 / 전체 데이터

Amount of say = $\frac{1}{2} \log(\frac{1-Total\ Error}{Total\ Error})$

New Sample Weight * $e^{Amount \ of \ say}$

New Sample Weight = Sample Weight * $e^{-Amount\ of\ say}$

대충 가중치를 부여한다는 뜻





| Feature A | Feature B | Feature C | Target | 가증치 |
|-----------|-----------|-----------|--------|------|
| Yes | Yes | 205 | Yes | 0.14 |
| No | Yes | 180 | Yes | 0.14 |
| Yes | No | 210 | Yes | 0.14 |
| Yes | Yes | 167 | Yes | 0.30 |
| No | Yes | 156 | No | 0.14 |
| No | No | 125 | No | 0.14 |

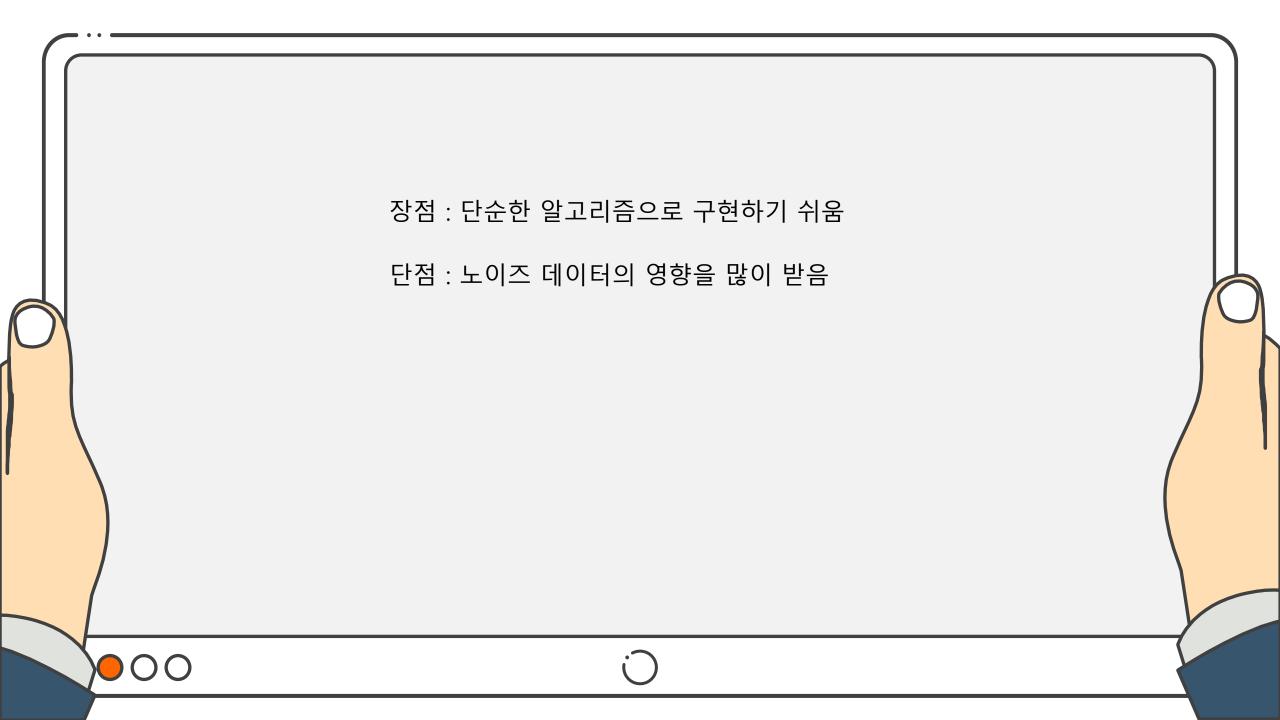


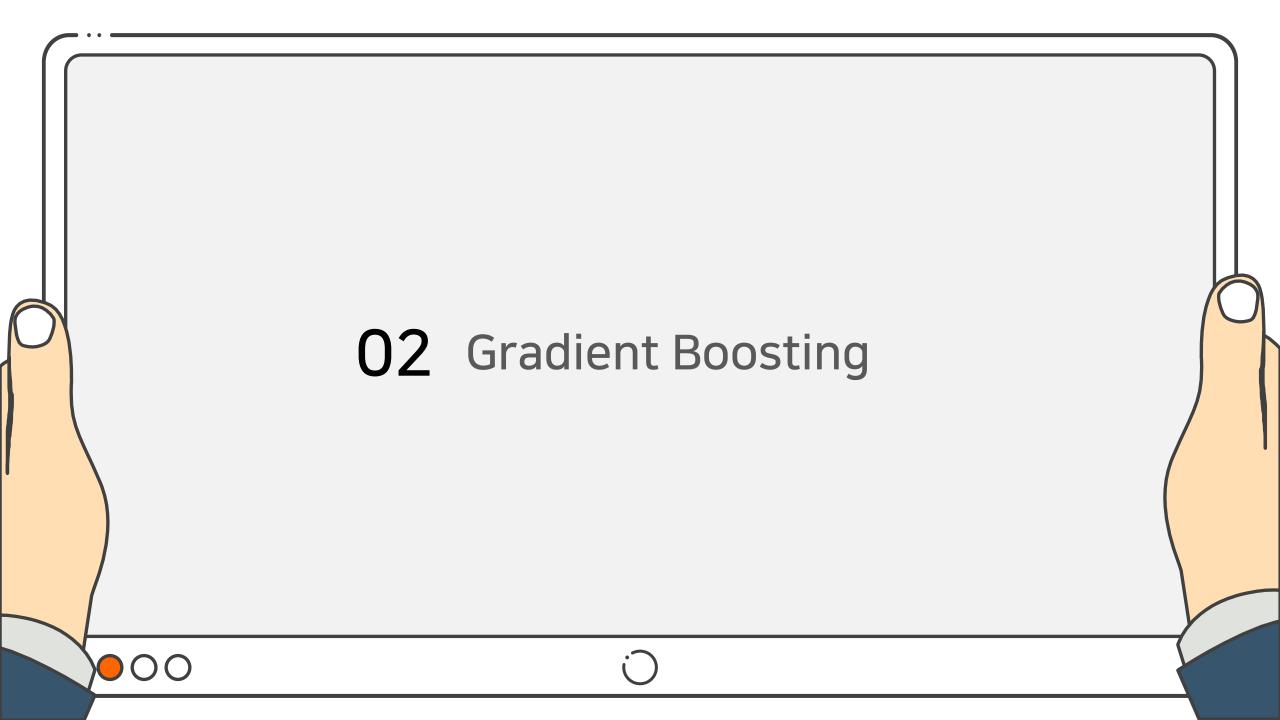


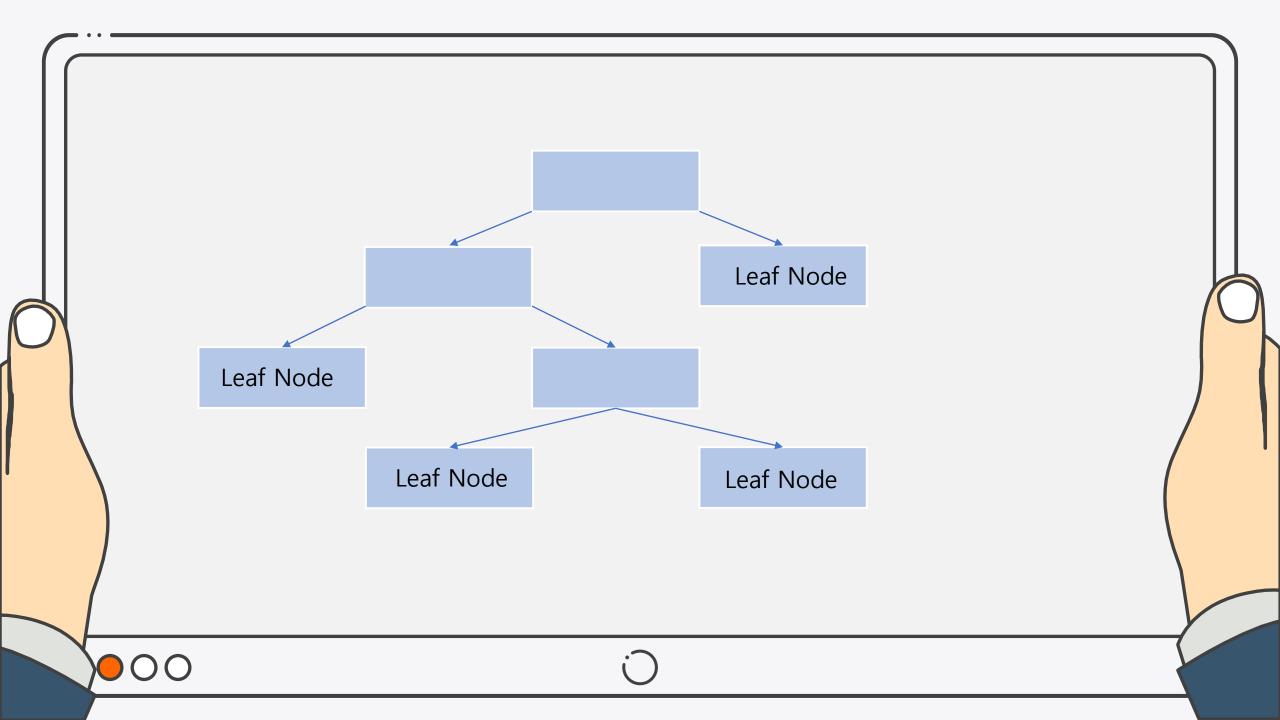
가중치 0.14 0.00 ~ 0.14 0.14 ~ 0.28 0.14 0.28 ~ 0.42 0.14 0.42 ~ 0.72 0.30 $0.72 \sim 0.86$ 0.14 0.86 ~ 1.00 0.14

1.초기에는 같은 값의 가중치를 부여한다 2.Stump중 가장 지니계수가 낮은(=잘 분류된) Stump를 선택 3.가중치를 업데이트 후 새로운 데이터 셋을 만든다, 4. 새로운 만들어진 데이터 셋으로 Stump를 다시 만든다. 5.이 과정을 일정 Loop 동안 반복한다.









| 키 | 좋아하는 색깔 | 성별 | 몸무게 |
|-----|---------|----|-----|
| 1.6 | 파랑 | 남성 | 88 |
| 1.6 | 초록 | 여성 | 76 |
| 1.5 | 파랑 | 여성 | 56 |
| 1.8 | 빨강 | 남성 | 73 |
| 1.5 | 초록 | 남성 | 77 |
| 1.4 | 파랑 | 여성 | 57 |





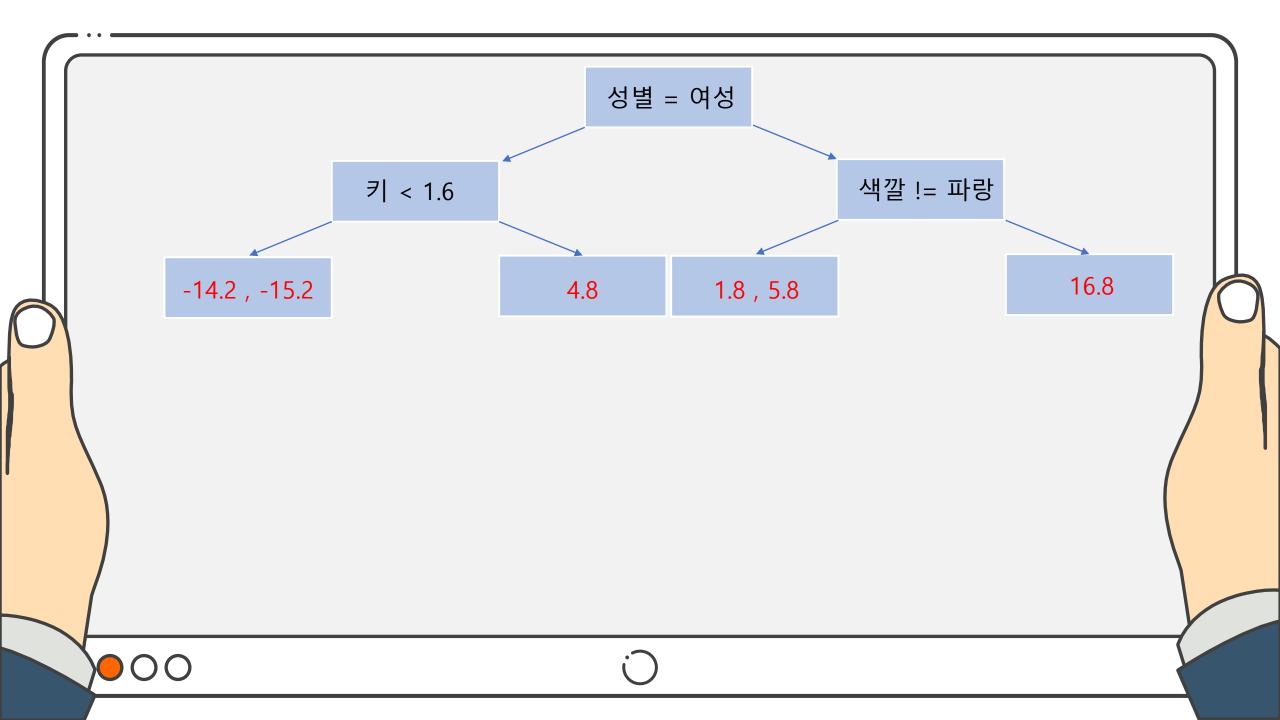
몸무게 평균 값 = 71.2

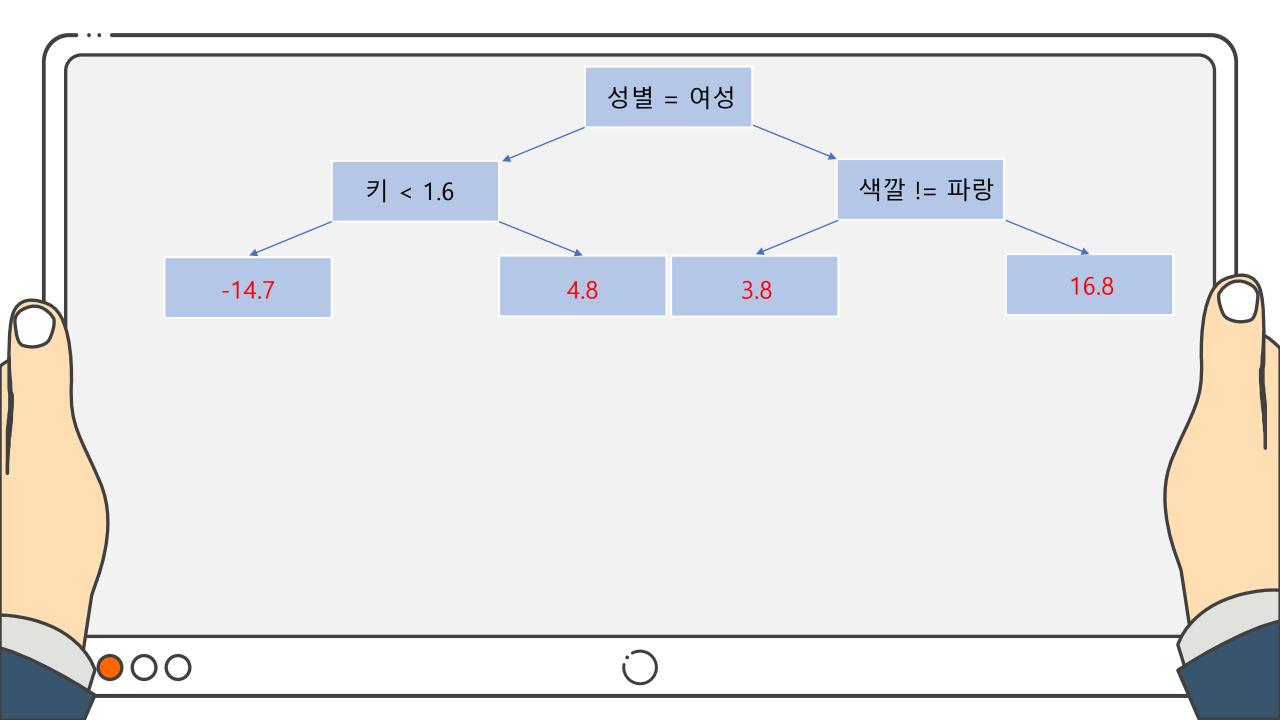
오차 88 – 71.2 76 – 71.2 56 – 71.2 73 – 71.2 77 – 71.2 57 – 71.2 000

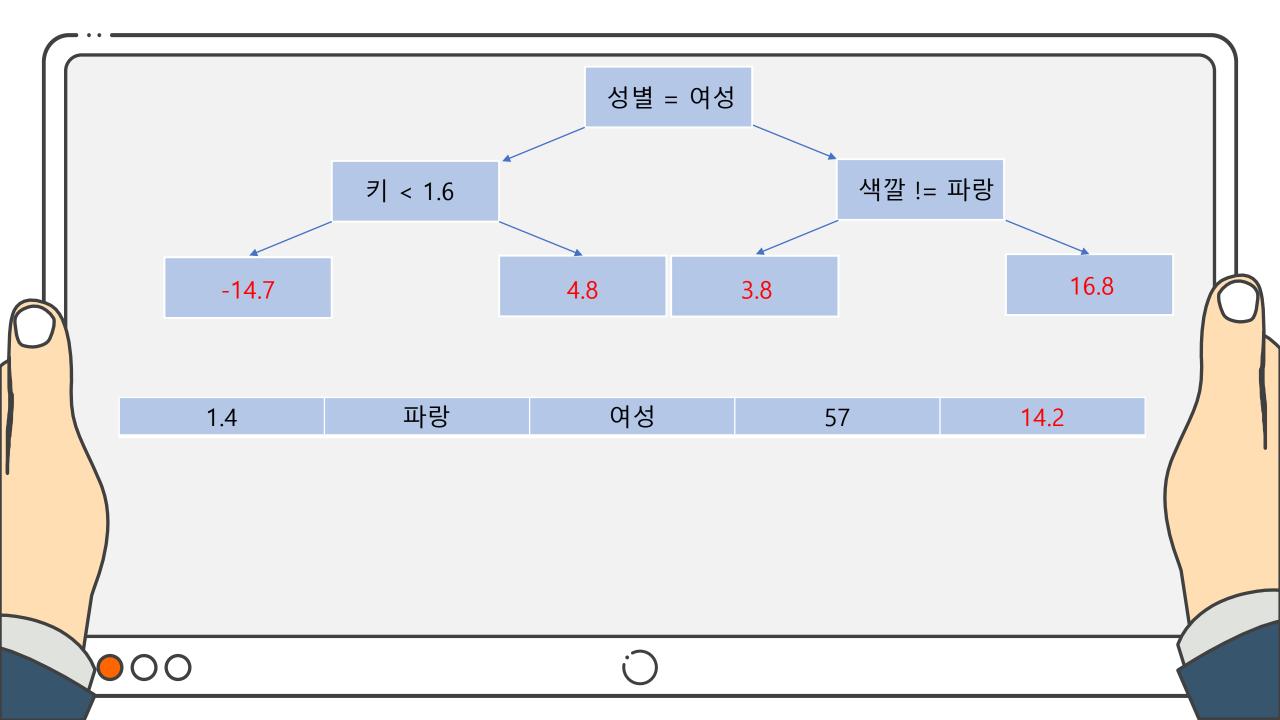
| ₹ | 좋아하는 색깔 | 성별 | 몸무게 | 오차 |
|-----|---------|----|-----|-------|
| 1.6 | 파랑 | 남성 | 88 | 16.8 |
| 1.6 | 초록 | 여성 | | 4.8 |
| 1.5 | 파랑 | 여성 | 56 | -15.2 |
| 1.8 | 빨강 | 남성 | | 1.8 |
| 1.5 | 초록 | 남성 | 77 | 5.8 |
| 1.4 | 파랑 | 여성 | | -14.2 |

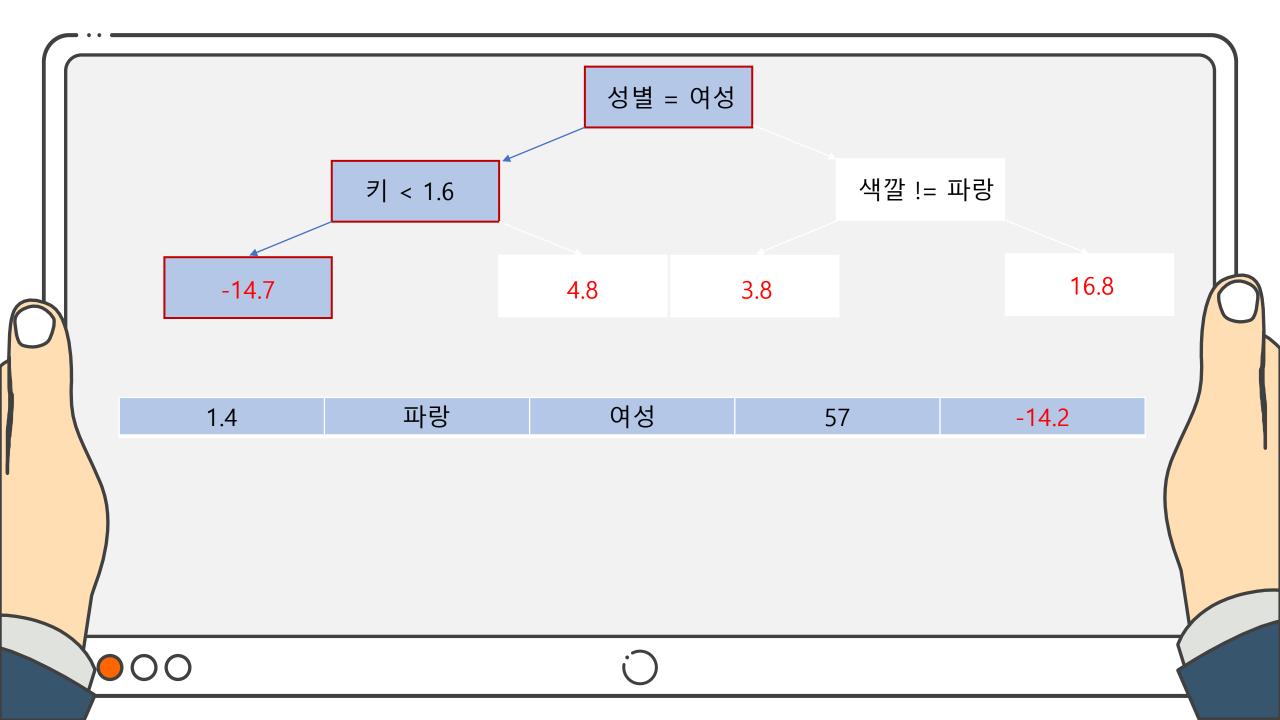


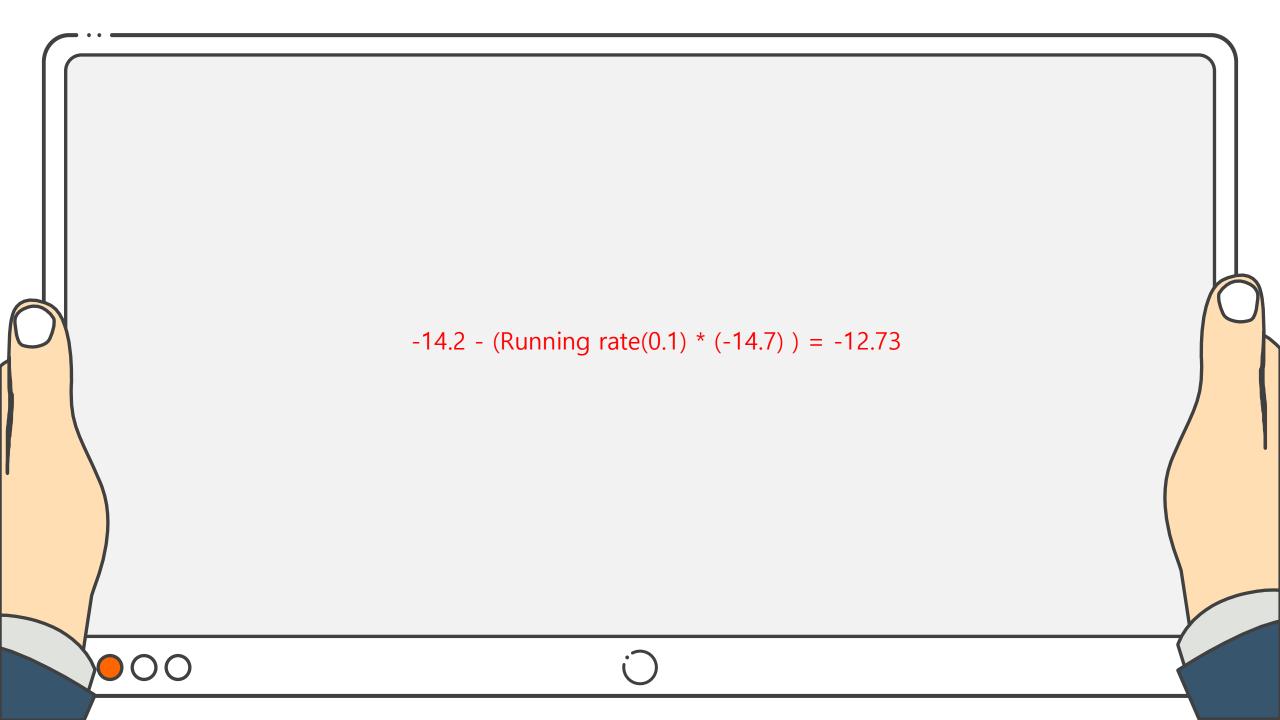








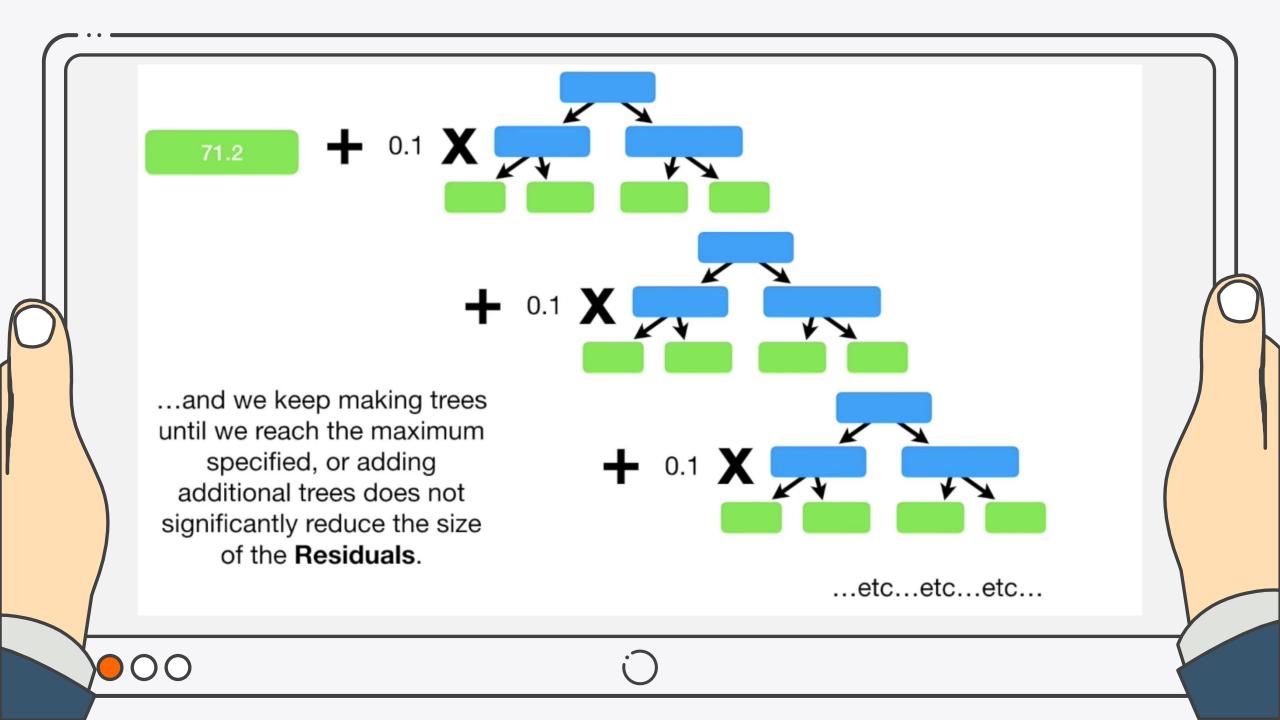




| ₹ | 좋아하는 색깔 | 성별 | 몸무게 | 오차 |
|-----|---------|----|-----|-------|
| 1.6 | 파랑 | 남성 | 88 | 15.1 |
| 1.6 | 초록 | 여성 | | 4.3 |
| 1.5 | 파랑 | 여성 | 56 | -13.7 |
| 1.8 | 빨강 | 남성 | | 1.4 |
| 1.5 | 초록 | 남성 | 77 | 5.4 |
| 1.4 | 파랑 | 여성 | | -12.7 |







- 1.초기에는 평균값으로 모든 예측 값을 예측한다.
- 2.실제 값과 오차를 구해, 해당 오차를 예측하는 Tree 를 만든다.
- 3.기존 예측 값에 오차 * learning rate 를 더해서,
- 4. 새로운 예측 값으로 업데이트 한다.
- 5.이 과정을 일정 Loop 동안 반복한다.

장점: Random Foest 보다 예측 성능이 뛰어남 단점: 1. 하이퍼 파라미터 튜닝 노력이 필요 2. 병렬처리를 지원하지 않기 때문에 학습에 매우 많은 시간이 필요

